

Implementasi Natural Language Processing pada Klasifikasi Artikel Berita Bahasa Inggris

Jeriko Ictus Seo

PENDAHULUAN

A. Latar Belakang

Perkembangan internet dan media digital menyebabkan jumlah artikel berita online meningkat dengan sangat cepat setiap harinya. Berbagai portal berita internasional mempublikasikan berita dalam berbagai kategori seperti World, Sports, Business, dan Sci/Tech. Banyaknya informasi yang tersedia membuat proses pengelompokan berita secara manual menjadi kurang efektif, terutama ketika jumlah data terus bertambah.

Natural Language Processing (NLP) merupakan salah satu cabang kecerdasan buatan yang digunakan untuk memproses, memahami, dan menganalisis bahasa manusia dalam bentuk teks. Salah satu penerapan NLP yang banyak digunakan adalah text classification atau klasifikasi teks, yaitu proses mengelompokkan dokumen ke dalam kategori tertentu secara otomatis berdasarkan isi teksnya.

Dalam penelitian ini digunakan dataset artikel berita Bahasa Inggris yang terdiri dari 7.600 data berita dengan tiga atribut utama yaitu Class Id, Title, dan Description. Dataset memiliki empat kategori berita, yaitu World, Sports, Business, dan Sci/Tech. Adanya label kategori pada dataset memungkinkan proses pelatihan model machine learning untuk melakukan klasifikasi berita secara otomatis.

Permasalahan dalam klasifikasi berita adalah adanya variasi penggunaan kata, panjang teks yang berbeda, serta banyaknya kata yang tidak memiliki makna penting dalam proses klasifikasi. Oleh karena itu diperlukan tahapan preprocessing seperti case folding, tokenization, stopword removal, dan stemming agar teks dapat diproses dengan lebih baik. Selain itu, metode ekstraksi fitur seperti TF-IDF digunakan untuk mengubah data teks menjadi representasi numerik yang dapat diproses oleh algoritma machine learning.

Melalui penelitian ini diharapkan dapat dihasilkan sistem klasifikasi berita berbasis Natural Language Processing yang mampu mengelompokkan artikel berita Bahasa Inggris secara otomatis dengan tingkat akurasi yang baik sehingga dapat membantu proses pengelolaan informasi menjadi lebih cepat dan efisien.

B. Rumusan Masalah

- Bagaimana mengimplementasikan Natural Language Processing pada klasifikasi artikel berita Bahasa Inggris?

- Bagaimana proses preprocessing teks untuk meningkatkan kualitas data berita sebelum dilakukan klasifikasi?
- Bagaimana penggunaan metode TF-IDF dalam mengubah teks berita menjadi data numerik?
- Bagaimana performa algoritma machine learning dalam melakukan klasifikasi artikel berita berdasarkan kategori World, Sports, Business, dan Sci/Tech?
- Bagaimana tingkat akurasi sistem klasifikasi berita yang dihasilkan dari penerapan Natural Language Processing?

C. Tujuan

- Mengimplementasikan Natural Language Processing pada klasifikasi artikel berita Bahasa Inggris.
- Melakukan preprocessing teks untuk meningkatkan kualitas data sebelum proses klasifikasi.
- Menerapkan metode TF-IDF untuk mengubah data teks menjadi representasi numerik.
- Membangun model machine learning untuk mengklasifikasikan artikel berita ke dalam kategori World, Sports, Business, dan Sci/Tech.
- Menganalisis performa model klasifikasi berdasarkan nilai accuracy, precision, recall, dan F1-score.

METODOLOGI

A. Jenis Penelitian

Jenis penelitian yang digunakan dalam penelitian ini adalah penelitian kuantitatif dengan pendekatan eksperimen.

Penelitian kuantitatif digunakan karena data yang diolah berupa data teks yang akan dikonversi menjadi data numerik menggunakan metode TF-IDF, kemudian dianalisis menggunakan algoritma machine learning. Pendekatan eksperimen dilakukan dengan cara membangun, menguji, dan mengevaluasi model klasifikasi artikel berita Bahasa Inggris untuk mengetahui tingkat performa sistem yang dihasilkan.

B. Sumber dataset

Dataset yang digunakan dalam penelitian ini berasal dari platform Kaggle dengan nama dataset:

https://www.kaggle.com/datasets/amananandrai/ag-news-classification-dataset?utm_source=chatgpt.com

Dataset terdiri dari 7.600 artikel berita Bahasa Inggris yang memiliki tiga atribut utama yaitu:

- Class Id
- Title
- Description

Dataset memiliki empat kategori berita, yaitu:

1. World
2. Sports
3. Business
4. Sci/Tech

Dataset digunakan sebagai data pelatihan dan pengujian dalam proses klasifikasi artikel berita menggunakan metode Natural Language Processing dan machine learning.

C. Tahapan Penelitian

a. Pengumpulan Data

Mengumpulkan dataset artikel berita Bahasa Inggris dari Kaggle untuk digunakan dalam proses penelitian.

b. Preprocessing Text

Tahap preprocessing dilakukan untuk membersihkan dan mempersiapkan data teks sebelum diproses oleh model machine learning. Tahapan yang dilakukan meliputi:

- Case Folding
- Tokenization
- Stopword Removal
- Stemming

c. Feature Extraction

Data teks diubah menjadi bentuk numerik menggunakan metode TF-IDF (Term Frequency – Inverse Document Frequency).

d. Pembagian Dataset

Dataset dibagi menjadi dua bagian, yaitu:

- Data Training
- Data Testing

Pembagian dilakukan untuk proses pelatihan dan pengujian model.

e. Proses Klasifikasi

Proses klasifikasi dilakukan menggunakan algoritma machine learning:

- Naive Bayes

f. Evaluasi Model

Evaluasi model dilakukan untuk mengetahui performa sistem klasifikasi menggunakan:

- Accuracy
- Precision
- Recall
- F1-Score

g. Analisis Hasil

Hasil klasifikasi dianalisis untuk mengetahui kemampuan model dalam mengelompokkan artikel berita sesuai kategori yang ditentukan.

D. Tools

- Pandas untuk membaca dan mengolah dataset
- NumPy untuk perhitungan numerik
- Matplotlib untuk visualisasi data
- Scikit-learn untuk implementasi algoritma K-Means dan normalisasi data

E. Algoritma Penelitian

START

LOAD AG News Dataset

READ data:

- Class Id
- Title
- Description

COMBINE Title and Description into one text column

FOR each article IN dataset DO

- CONVERT text to lowercase // Case Folding
- TOKENIZE text into words // Tokenization
- REMOVE stopwords // Stopword Removal
- APPLY stemming // Stemming

END FOR

TRANSFORM text using TF-IDF

SPLIT dataset into:

- Training Data
- Testing Data

TRAIN Naive Bayes model using Training Data

PREDICT category using Testing Data

CALCULATE evaluation metrics:

- Accuracy
- Precision
- Recall
- F1-Score

DISPLAY classification results

END

HASIL DAN PEMBAHASAN

KESIMPULAN

DAFTAR PUSTAKA